
Méthodes de ranking et recommandation

Projet 7 : Simulation d'un Google Bombing

Rapport de projet

Formation :
Master 1 Informatique

Réalisé par :

— Douadjia Abdelkarim
— Issaadi Dorsaf

Responsable de matière :

Monsieur Franck Quessette

Année universitaire :

2025 – 2026

Table des matières

1	Introduction	2
2	Organisation des fichiers du projet	2
3	Rappels théoriques	3
3.1	Matrice Google et PageRank	3
3.2	Convergence sur Harvard500	4
4	Protocole expérimental	4
4.1	Graphes utilisés	4
4.2	Sélection des cibles	4
4.3	Structures d'attaque	5
5	Résultats sur Harvard500	6
5.1	Évolution du score PageRank absolu	6
5.2	Gain relatif	6
5.3	Tableau de synthèse	7
6	Analyse et interprétation sur Harvard500	7
6.1	Sommets isolés : attaque la plus efficace	7
6.2	Graphe complet : saturation par dilution interne	8
6.3	Anneau : efficace pour de petits cycles	8
6.4	Effet du type de cible	8
7	Comparaison multi-graphes	9
7.1	Comportement sur courtois.txt	9
7.2	Comportement sur Wikipedia	9
7.3	Comparaison synthétique des trois graphes	10
7.4	Analyse des différences entre graphes	11
8	Règles empiriques	12
9	Conclusion	12

Résumé

Ce rapport présente une simulation de *Google Bombing* dans le cadre du projet 7. À partir d'un graphe du Web, on calcule d'abord le PageRank initial, puis on choisit trois cibles : une page de forte pertinence, une page de pertinence médiane et une page de faible pertinence. On ajoute ensuite trois structures d'attaque : des sommets isolés, un graphe complet et un anneau.

Les expériences sont menées sur trois graphes de tailles différentes : `courtois.txt`, `Harvard500` et un graphe Wikipedia. Les résultats montrent que l'attaque par sommets isolés est la plus efficace lorsque le nombre d'attaquants augmente. L'anneau peut être intéressant pour de petites valeurs de k , tandis que le graphe complet est souvent limité par la dilution interne de la masse PageRank.

1 Introduction

Le *Google Bombing* est une technique de manipulation du référencement qui exploite la structure des hyperliens du Web pour augmenter artificiellement le score PageRank d'une page cible. En ajoutant dans le graphe du Web un sous-graphe composé de pages contrôlées, appelées *attaquants*, pointant vers la cible, un acteur malveillant peut faire remonter artificiellement la pertinence d'une page dans un classement basé sur PageRank.

Dans ce projet, nous reprenons l'algorithme PageRank vu en TD et nous le modifions pour simuler plusieurs structures d'attaque. Le but est de comparer le PageRank de la cible avant et après l'ajout des attaquants.

Nous faisons varier :

- le nombre k d'attaquants ;
- la structure du sous-graphe attaquant : isolés, complet ou anneau ;
- le type de cible : forte, médiane ou faible ;
- le graphe de départ.

Une attaque est considérée comme efficace lorsque la probabilité PageRank de la cible devient significativement plus forte.

2 Organisation des fichiers du projet

La table 1 résume les fichiers principaux utilisés dans le projet.

TABLE 1 – Rôle des fichiers principaux du projet.

Fichier ou dossier	Rôle
googlebombing.c	Programme principal en C. Il lit les graphes, calcule le PageRank initial, ajoute les structures d'attaque et exporte les résultats.
data/	Dossier contenant les graphes utilisés dans les expériences.
results/	Dossier contenant les résultats numériques produits par les simulations.
images/	Dossier contenant les figures utilisées dans le rapport.
rapport.pdf	Rapport final généré à partir du code $\text{\LaTeX}$.

3 Rappels théoriques

3.1 Matrice Google et PageRank

Soit $\mathcal{G} = (V, E)$ un graphe orienté à n sommets. Chaque sommet représente une page Web et chaque arc représente un lien hypertexte.

On note $\mathbf{H} \in \mathbb{R}^{n \times n}$ la matrice hyperlien :

$$H_{ij} = \begin{cases} \frac{1}{d_i} & \text{si } (i, j) \in E \text{ et } d_i > 0, \\ 0 & \text{sinon,} \end{cases}$$

où d_i est le nombre de liens sortants de la page i .

Définition 1 (Matrice Google). La matrice Google est définie par :

$$\mathbf{G} = \alpha \mathbf{H}' + (1 - \alpha) \mathbf{e} \mathbf{z}^\top,$$

où $\mathbf{H}'$ est la matrice hyperlien corrigée pour les pages sans lien sortant, $\mathbf{z}$ est le vecteur de personnalisation uniforme, et $\alpha \in (0, 1)$ est le facteur d'amortissement.

Définition 2 (Vecteur PageRank). Le vecteur PageRank $\boldsymbol{\pi}^*$ est la distribution stationnaire vérifiant :

$$\boldsymbol{\pi}^* = \boldsymbol{\pi}^* \mathbf{G}, \quad \|\boldsymbol{\pi}^*\|_1 = 1, \quad \boldsymbol{\pi}^* \geq 0.$$

Il est calculé par la méthode des puissances :

$$\boldsymbol{\pi}^{(k+1)} = \boldsymbol{\pi}^{(k)} \mathbf{G},$$

jusqu'à ce que :

$$\|\pi^{(k+1)} - \pi^{(k)}\|_1 \leq \varepsilon.$$

3.2 Convergence sur Harvard500

Avec $\alpha = 0,85$ et $\varepsilon = 10^{-6}$, la convergence du PageRank initial sur Harvard500 est atteinte en **47 itérations**. La norme L_1 décroît de manière géométrique, ce qui correspond au comportement attendu de la méthode des puissances.




FIGURE 1 – Décroissance de la norme L_1 lors du calcul du PageRank initial sur Harvard500.

4 Protocole expérimental

4.1 Graphes utilisés

Trois graphes de tailles différentes sont utilisés afin d'évaluer la robustesse des résultats. Le graphe `courtois.txt` sert de cas jouet, Harvard500 est le graphe principal, et Wikipedia permet de tester le passage à grande échelle.

TABLE 2 – Caractéristiques des graphes expérimentaux.

Graphe	Rôle	n	m	Convergence
<code>courtois.txt</code>	Graphe jouet	8	41	42 itérations
Harvard500	Graphe principal	500	2 636	47 itérations
Wikipedia	Grande échelle	1 634 989	19 753 078	35 itérations

4.2 Sélection des cibles

Après le calcul du PageRank initial, les pages sont triées par score décroissant. On choisit ensuite trois cibles :

- une cible forte, située dans le haut du classement ;
- une cible médiane, située autour du milieu du classement ;
- une cible faible, située dans le bas du classement.

Pour éviter les cas trop particuliers, les cibles sont choisies par percentile.

TABLE 3 – Cibles sélectionnées pour chaque graphe.

Graphe	Type	Page	PR ₀	Critère
courtois.txt	Forte	6	$1,849 \times 10^{-1}$	Top 10%
	Médiane	4	$1,092 \times 10^{-1}$	Médiane
	Faible	2	$7,641 \times 10^{-2}$	Bottom 10%
Harvard500	Forte	219	$2,835 \times 10^{-3}$	Top 10%
	Médiane	13	$6,461 \times 10^{-4}$	Médiane
	Faible	121	$3,000 \times 10^{-4}$	Bottom 10%
Wikipedia	Forte	397700	$7,768 \times 10^{-7}$	Top 10%
	Médiane	694255	$1,429 \times 10^{-7}$	Médiane
	Faible	1471490	$1,009 \times 10^{-7}$	Bottom 10%

4.3 Structures d'attaque

Trois structures de graphes attaquants sont comparées. Dans chaque cas, k désigne le nombre de nouveaux sommets attaquants ajoutés, et la cible est un sommet déjà présent dans le graphe initial.




FIGURE 2 – Les trois structures de Google Bombing étudiées pour $k = 3$ attaquants.

Sommets isolés. Chaque attaquant possède un unique lien sortant vers la cible. Toute sa masse PageRank est donc transmise directement à la cible.

Graphe complet. Les attaquants pointent vers la cible, mais aussi entre eux. La masse PageRank est donc partagée entre la cible et les autres attaquants.

Anneau. La cible fait partie d'un cycle avec les attaquants :

$$a_1 \rightarrow a_2 \rightarrow \dots \rightarrow a_k \rightarrow t \rightarrow a_1.$$

La masse circule en boucle et repasse régulièrement par la cible.

5 Résultats sur Harvard500

5.1 Évolution du score PageRank absolu

La figure 3 montre le score PageRank de la cible en fonction de k pour les trois types de cibles.





FIGURE 3 – Score PageRank absolu de la cible en fonction de k sur Harvard500.

5.2 Gain relatif

Pour comparer les attaques indépendamment du score initial, on utilise le gain relatif :

$$\gamma(k) = \frac{PR_k(t)}{PR_0(t)}.$$

FIGURE 4 – Gain relatif γ pour chaque combinaison structure/cible sur Harvard500.

5.3 Tableau de synthèse

TABLE 4 – Gain relatif $\gamma = PR/PR_0$ pour les valeurs clés de k sur Harvard500.

Cible	Structure	$k = 1$	$k = 10$	$k = 50$	$k = 100$
Forte	Isolés	1,09×	1,93×	5,31×	8,91×
	Complet	1,09×	1,38×	1,44×	1,34×
	Anneau	1,43×	1,54×	1,46×	1,34×
Médiane	Isolés	1,39×	4,86×	18,9×	33,8×
	Complet	1,39×	2,63×	3,06×	2,91×
	Anneau	1,83×	3,24×	3,30×	3,03×
Faible	Isolés	1,85×	9,31×	39,5×	71,7×
	Complet	1,85×	4,53×	5,54×	5,30×
	Anneau	2,89×	5,94×	6,06×	5,56×

6 Analyse et interprétation sur Harvard500

6.1 Sommets isolés : attaque la plus efficace

L'attaque par sommets isolés est la plus redoutable. Chaque attaquant possède un seul lien sortant, dirigé vers la cible. Il n'y a donc pas de perte de masse vers d'autres attaquants.

La croissance du gain relatif est presque linéaire. Pour la cible faible, le gain atteint 71,7× avec $k = 100$. Cela signifie que le score PageRank de la cible faible est multiplié par plus de 71.

Remarque 6.1. Les sommets isolés paraissent simples, mais ils sont très efficaces parce que toute la masse PageRank disponible est concentrée vers la cible.

6.2 Graphe complet : saturation par dilution interne

Le graphe complet contient beaucoup d'arcs, mais il n'est pas optimal. Chaque attaquant pointe vers la cible, mais aussi vers tous les autres attaquants. Ainsi, une partie importante de la masse reste dans le sous-graphe attaquant.

Quand k augmente, le nombre d'attaquants augmente, mais la fraction envoyée par chaque attaquant vers la cible diminue. Cela explique la saturation du gain.

$$\text{Flux vers la cible} \simeq k \times \frac{\text{PR}(a_i)}{k}.$$

Cette approximation explique pourquoi le graphe complet plafonne rapidement.

6.3 Anneau : efficace pour de petits cycles

L'anneau force la masse à revenir régulièrement vers la cible. Pour de petites valeurs de k , le cycle est court et l'effet peut être fort. C'est pour cela que l'anneau dépasse souvent le graphe complet au début.

Cependant, quand k devient grand, le cycle devient plus long. La masse met plus de temps à revenir vers la cible, ce qui explique la saturation puis le léger déclin observé.

6.4 Effet du type de cible

Le type de cible joue un rôle central. Le gain relatif s'écrit :

$$\gamma = 1 + \frac{\Delta\pi}{\text{PR}_0}.$$

Pour une même augmentation absolue $\Delta\pi$, le gain relatif est plus grand lorsque PR_0 est petit. C'est la raison pour laquelle les cibles faibles sont beaucoup plus faciles à booster en ratio que les cibles fortes.

Avec $k = 100$ isolés :

- cible forte : gain de 8,91×;
- cible médiane : gain de 33,8×;
- cible faible : gain de 71,7×.

7 Comparaison multi-graphes

7.1 Comportement sur courtois.txt

Sur le petit graphe `courtois.txt`, les scores PageRank initiaux sont beaucoup plus élevés que sur Harvard500. L'effet de levier est donc plus faible : une augmentation absolue de PageRank produit un ratio moins spectaculaire.

TABLE 5 – Gain relatif γ sur `courtois.txt`.

Cible	Structure	$k = 1$	$k = 10$	$k = 50$	$k = 100$
Forte	Isolés	1,24×	2,18×	2,83×	2,97×
	Complet	1,24×	1,18×	0,87×	0,26×
	Anneau	0,43×	0,43×	0,15×	0,08×
Médiane	Isolés	1,35×	2,75×	3,71×	3,91×
	Complet	1,35×	1,42×	1,05×	0,32×
	Anneau	0,59×	0,64×	0,23×	0,12×
Faible	Isolés	1,26×	2,31×	3,04×	3,19×
	Complet	1,26×	1,24×	0,91×	0,27×
	Anneau	1,06×	1,04×	0,36×	0,20×

Un phénomène important apparaît : sur ce très petit graphe, l'anneau peut diminuer le PageRank de la cible. Cela vient du fait que l'anneau ajoute un lien sortant depuis la cible vers le premier attaquant. Sur un petit graphe, ce lien supplémentaire modifie fortement la répartition de la masse.

7.2 Comportement sur Wikipedia

Sur le graphe Wikipedia, les expériences sont limitées à $k_{\max} = 20$ en raison du coût de calcul. Malgré cette limite, les tendances restent cohérentes avec Harvard500 : les sommets isolés donnent le meilleur gain, surtout pour les cibles faibles.

TABLE 6 – Gain relatif γ sur Wikipedia avec $k_{\max} = 20$.

Cible	Structure	$k = 1$	$k = 5$	$k = 10$	$k = 20$
Forte	Isolés	1,11×	1,56×	2,11×	3,22×
	Complet	1,11×	1,35×	1,47×	1,58×
	Anneau	1,14×	1,43×	1,60×	1,71×
Médiane	Isolés	1,61×	4,04×	7,08×	13,16×
	Complet	1,61×	2,90×	3,59×	4,16×
	Anneau	1,83×	3,47×	4,37×	4,91×
Faible	Isolés	1,85×	5,25×	9,50×	18,00×
	Complet	1,85×	3,66×	4,62×	5,42×
	Anneau	1,95×	4,27×	5,62×	6,46×




FIGURE 5 – Gain relatif sur Wikipedia. Les sommets isolés progressent linéairement, tandis que le complet et l'anneau saturent rapidement.

7.3 Comparaison synthétique des trois graphes

La figure 6 compare le gain relatif de la cible faible pour l'attaque par sommets isolés. Cette attaque est la plus efficace dans les expériences principales.




FIGURE 6 – Comparaison du gain relatif de la cible faible pour l'attaque par sommets isolés.

TABLE 7 – Gain relatif γ à $k = 10$ pour les trois graphes.

Graphe	Structure	Forte	Médiane	Faible
courtois ($n = 8$)	Isolés	2,18×	2,75×	2,31×
	Complet	1,18×	1,42×	1,24×
	Anneau	0,43×	0,64×	1,04×
Harvard500 ($n = 500$)	Isolés	1,93×	4,86×	9,31×
	Complet	1,38×	2,63×	4,53×
	Anneau	1,54×	3,24×	5,94×
Wikipedia ($n = 1,6 \text{ M}$)	Isolés	2,11×	7,08×	9,50×
	Complet	1,47×	3,59×	4,62×
	Anneau	1,60×	4,37×	5,62×

7.4 Analyse des différences entre graphes

Trois phénomènes expliquent les différences observées entre les graphes.

Effet de levier. Le score initial des cibles est beaucoup plus élevé sur `courtois.txt` que sur Harvard500 ou Wikipedia. Le gain relatif est donc plus faible sur `courtois.txt`, car :

$$\gamma = 1 + \frac{\Delta\pi}{PR_0}.$$

Si PR_0 est grand, le même gain absolu produit un ratio plus petit.

Dilution avec la taille du graphe. Sur un très grand graphe, la masse de téléportation est distribuée sur beaucoup plus de sommets. L'effet absolu d'un attaquant est donc plus faible. Cependant, les

cibles faibles ont aussi un PageRank initial très faible, ce qui permet de garder un gain relatif important.

Cas particulier des petits graphes. Sur `courtois.txt`, l'anneau peut être défavorable. L'ajout d'un arc sortant depuis la cible vers le premier attaquant modifie fortement le degré sortant de la cible. Cet effet est beaucoup moins visible sur des graphes plus grands.

8 Règles empiriques

Les expériences permettent de déduire les règles suivantes :

1. **Les sommets isolés sont l'attaque la plus efficace pour grand k .** Leur masse est transmise directement vers la cible, sans dilution interne.
2. **Le graphe complet est rarement optimal.** Les liens internes retiennent une partie de la masse PageRank entre les attaquants.
3. **L'anneau est intéressant pour petit k .** Le cycle ramène régulièrement la masse vers la cible, mais l'effet diminue lorsque le cycle devient long.
4. **Les cibles faibles sont les plus vulnérables en ratio.** Leur PageRank initial est faible, donc une petite augmentation absolue donne un grand gain relatif.
5. **Les très petits graphes peuvent avoir des comportements particuliers.** Sur `courtois.txt`, l'ajout d'un arc sortant depuis la cible dans l'anneau peut dégrader son score.

9 Conclusion

Cette étude montre qu'un Google Bombing peut augmenter significativement le PageRank d'une page cible. L'efficacité dépend principalement du nombre d'attaquants, de la structure du graphe attaquant et du PageRank initial de la cible.

Sur Harvard500, l'attaque par sommets isolés est la plus efficace. Pour la cible faible, le gain atteint $71,7\times$ avec $k = 100$. Pour la cible médiane, il atteint $33,8\times$, tandis que la cible forte reste plus difficile à faire progresser.

Le graphe complet et l'anneau sont moins efficaces à grande échelle. Le graphe complet dilue la masse entre les attaquants, tandis que l'anneau est surtout utile pour de petites valeurs de k . Ces résultats confirment que les pages faibles sont les plus sensibles au Google Bombing et justifient les mécanismes modernes de détection des fermes de liens.

Références

- [1] S. Brin, L. Page, *The Anatomy of a Large-Scale Hypertextual Web Search Engine*, Computer Networks and ISDN Systems, 30(1–7) :107–117, 1998.
- [2] A. N. Langville, C. D. Meyer, *Google's PageRank and Beyond : The Science of Search Engine Rankings*, Princeton University Press, 2006.
- [3] M. Bianchini, M. Gori, F. Scarselli, *Inside PageRank*, ACM Transactions on Internet Technology, 5(1) :92–128, 2005.
- [4] T. A. Davis, Y. Hu, *The University of Florida Sparse Matrix Collection*, ACM Transactions on Mathematical Software, 38(1) :1–25, 2011.