

Simulation d'un Google Bombing

Analyse expérimentale de trois structures d'attaque
sur plusieurs graphes du Web

Projet PageRank — Algorithmes et Graphes

Rapport de projet

May 16, 2026

Contents

1	Introduction	1
2	Rappels théoriques	1
2.1	Matrice Google et PageRank	1
2.2	Convergence sur Harvard500	2
3	Protocole expérimental	2
3.1	Graphes utilisés	2
3.2	PageRank initial et sélection des cibles	3
3.3	Structures d'attaque	3
4	Résultats sur Harvard500	4
4.1	Évolution du score PageRank absolu	4
4.2	Facteur de gain relatif	5
4.3	Tableau de synthèse	6
5	Analyse et interprétation (Harvard500)	6
5.1	Nœuds isolés : attaque optimale à croissance linéaire	6
5.2	Graphe complet : saturation par dilution interne	7
5.3	Anneau : efficacité intermédiaire avec saturation	7
5.4	Impact du type de cible : effet de levier	8
6	Comparaison multi-graphes	8
6.1	Vue d'ensemble	8
6.2	Comportement sur le graphe jouet <code>courtois.txt</code>	8

6.3	Comportement sur Wikipedia ($n = 1,6$ M)	9
6.4	Comparaison synthétique des trois graphes	10
6.5	Analyse des différences entre graphes	10
6.6	Tableau de comparaison à $k = 10$	11
7	Règles empiriques et conclusion	12
7.1	Règles empiriques	12
7.2	Conclusion	12

1 Introduction

Le *Google Bombing* est une technique de manipulation du référencement qui exploite la structure hyperliens du Web pour augmenter artificiellement le score PageRank d’une page cible. En ajoutant dans le graphe du Web un sous-graphe composé de pages contrôlées — les *attaquants* — pointant vers la cible, un acteur malveillant peut remonter la pertinence de n’importe quelle page dans les résultats d’un moteur de recherche basé sur PageRank.

Ce rapport étudie expérimentalement l’efficacité de trois structures d’attaque en faisant varier :

- le nombre k d’attaquants ($k \in \{1, \dots, 100\}$) ;
- la structure du sous-graphe attaquant (isolés, complet, anneau) ;
- le type de cible (pertinence forte, médiane ou faible) ;
- le graphe cible, afin de mesurer la robustesse des résultats.

Les expériences sont menées sur trois graphes de tailles très différentes, avec le facteur d’amortissement classique $\alpha = 0,85$.

2 Rappels théoriques

2.1 Matrice Google et PageRank

Soit $\mathcal{G} = (V, E)$ un graphe orienté à n sommets. On note $\mathbf{H} \in \mathbb{R}^{n \times n}$ la matrice hyperlien : $H_{ij} = 1/d_i$ si $(i, j) \in E$ et $d_i > 0$, sinon $H_{ij} = 0$.

Définition 1 (Matrice Google).

$$\mathbf{G} = \alpha \mathbf{H}' + (1 - \alpha) \mathbf{e} \mathbf{z}^\top,$$

où $\mathbf{H}'$ est la matrice $\mathbf{H}$ dont les lignes nulles (nœuds *dangling*) sont remplacées par $\mathbf{z}^\top$ (vecteur de personnalisation uniforme $z_i = 1/n$), et $\alpha \in (0, 1)$ est le facteur de téléportation.

Définition 2 (Vecteur PageRank). Le vecteur PageRank π^* est l'unique distribution de probabilité stationnaire de $\mathbf{G}$:

$$\pi^* = \pi^* \mathbf{G}, \quad \|\pi^*\|_1 = 1, \quad \pi^* \geq 0.$$

Il est calculé par la *méthode des puissances* : $\pi^{(k+1)} = \pi^{(k)} \mathbf{G}$, avec critère d'arrêt $\|\pi^{(k+1)} - \pi^{(k)}\|_1 \leq \varepsilon$.

2.2 Convergence sur Harvard500

Avec $\alpha = 0,85$ et $\varepsilon = 10^{-6}$, la convergence est atteinte en **47 itérations**. La décroissance de la norme L_1 est géométrique de raison $\approx \alpha = 0,85$, conformément à la théorie (figure 1).




Figure 1: Décroissance géométrique de la norme L_1 lors du calcul du PageRank initial sur Harvard500. L'axe des ordonnées est en échelle logarithmique.

3 Protocole expérimental

3.1 Graphes utilisés

Trois graphes de tailles très différentes sont utilisés afin de mesurer la robustesse des résultats à l'échelle :

Table 1: Caractéristiques des trois graphes expérimentaux

Graphe	Format	n	m	Conv. (it.)
courtois.txt	.txt	8	41	42
Harvard500.mtx	.mtx	500	2 636	47
wikipedia-20051105V2	.txt	1 634 989	19 753 078	35

Le graphe `courtois.txt` sert de cas jouet pour la vérification ; `Harvard500.mtx` constitue le jeu de données principal de l'analyse ; le graphe Wikipedia (format Matrix Market) permet de tester la généralisabilité à grande échelle.

3.2 PageRank initial et sélection des cibles

Après calcul du PageRank initial, la distribution est très concentrée : la page 6 capture 10,36 % de la masse totale sur Harvard500, tandis que de nombreuses pages en bas de classement atteignent le plancher de téléportation $\approx 3,0 \times 10^{-4}$.

Pour éviter les cas atypiques, les trois cibles sont sélectionnées par percentile :

Table 2: Cibles sélectionnées pour chaque graphe

Graphe	Type	Page	PR ₀	Critère
<code>courtois.txt</code>	Forte	6	$1,849 \times 10^{-1}$	Top 10%
	Médiane	4	$1,092 \times 10^{-1}$	Médiane
	Faible	2	$7,641 \times 10^{-2}$	Bottom 10%
<code>Harvard500.mtx</code>	Forte	219	$2,835 \times 10^{-3}$	Top 10%
	Médiane	13	$6,461 \times 10^{-4}$	Médiane
	Faible	121	$3,000 \times 10^{-4}$	Bottom 10%
Wikipedia	Forte	397700	$7,768 \times 10^{-7}$	Top 10%
	Médiane	694255	$1,429 \times 10^{-7}$	Médiane
	Faible	1471490	$1,009 \times 10^{-7}$	Bottom 10%

3.3 Structures d'attaque

Trois sous-graphes attaquants sont ajoutés au graphe de base. Dans les trois cas, k désigne le nombre de nœuds attaquants ajoutés, et la cible est un nœud déjà présent dans le graphe.




Figure 2: Illustration des trois structures pour $k = 3$ attaquants. (a) Étoile entrante pure. (b) Clique interne + lien vers la cible. (c) Cycle intégrant la cible.

(a) **Nœuds isolés.** Chaque attaquant a_i possède un unique lien sortant vers la cible. Il transfère l'intégralité de sa masse PageRank vers t .

(b) **Graphe complet.** Les k attaquants forment un graphe complet entre eux ($k(k-1)$ arcs) et pointent chacun vers la cible. Chaque attaquant a k liens sortants, donc n'envoie qu'une fraction $1/k$ de sa masse à la cible.

(c) **Anneau.** Les k attaquants et la cible forment un cycle : $a_1 \rightarrow a_2 \rightarrow \dots \rightarrow a_k \rightarrow \text{cible} \rightarrow a_1$. La masse circule en boucle et la cible bénéficie d'une accumulation cyclique. Un arc supplémentaire est ajouté à la cible (vers a_1), augmentant son degré sortant d'une unité.

4 Résultats sur Harvard500

4.1 Évolution du score PageRank absolu

La figure 3 montre le score PageRank de la cible en fonction de k pour les neuf combinaisons (3 structures $\times$ 3 cibles).




Figure 3: Score PageRank absolu de la cible en fonction de k pour les trois structures et les trois types de cibles sur Harvard500 (ligne grise = score initial PR_0).

4.2 Facteur de gain relatif

Pour comparer objectivement les attaques indépendamment du score initial, on définit le **gain relatif** :

$$\gamma(k) = \frac{PR_k(t)}{PR_0(t)}.$$

Gain relatif selon la structure et le type de cible ($\alpha = 0,85$)




Figure 4: Gain relatif γ pour chaque combinaison (structure, cible) sur Harvard500. Ligne pleine : isolés (croissance linéaire continue) ; tiretée : complet (saturation rapide) ; pointillée : anneau (saturation puis léger déclin).

4.3 Tableau de synthèse

Table 3: Gain relatif $\gamma = PR/PR_0$ pour les valeurs clés de k — Harvard500

Cible	Structure	$k = 1$	$k = 10$	$k = 50$	$k = 100$
Forte	Isolés	1,09×	1,93×	5,31×	8,91×
	Complet	1,09×	1,38×	1,44×	1,34×
	Anneau	1,43×	1,54×	1,46×	1,34×
Médiane	Isolés	1,39×	4,86×	18,9×	33,8×
	Complet	1,39×	2,63×	3,06×	2,91×
	Anneau	1,83×	3,24×	3,30×	3,03×
Faible	Isolés	1,85×	9,31×	39,5×	71,7×
	Complet	1,85×	4,53×	5,54×	5,30×
	Anneau	2,89×	5,94×	6,06×	5,56×

5 Analyse et interprétation (Harvard500)

5.1 Nœuds isolés : attaque optimale à croissance linéaire

L'attaque par nœuds isolés est de loin la plus redoutable. Son gain relatif croît **linéairement** en k , sans saturation visible dans $[1, 100]$.

Explication analytique. Chaque nœud attaquant a_i n’ayant aucun lien sortant sauf vers la cible t , il est lui-même un nœud dangling vis-à-vis du reste du graphe étendu : sa masse stationnaire est entièrement réinvestie dans la cible via la méthode des puissances. Pour k attaquants isolés dans un graphe de taille $n \gg k$, le score de la cible s’écrit en première approximation :

$$\text{PR}_k(t) \approx \text{PR}_0(t) + k \cdot c, \quad c = \frac{(1 - \alpha)}{n + k} \cdot \text{const} > 0.$$

La contribution de chaque attaquant est indépendante des autres (pas de dilution mutuelle), d’où la croissance linéaire observée. À $k = 100$ isolés, la cible faible atteint $\gamma = 71,7\times$, multipliant son score initial par plus de 71.

5.2 Graphe complet : saturation par dilution interne

Le graphe complet sature rapidement (dès $k \approx 30\text{--}45$ selon la cible) puis **décroît légèrement**. Pour la cible forte, le gain plafonne à $\approx 1,46\times$ puis redescend à $1,34\times$ pour $k = 100$.

Explication. Dans un graphe complet à k sommets, chaque attaquant dispose de k liens sortants : un vers la cible, $k - 1$ vers les autres attaquants. La fraction envoyée à la cible est $1/k$. Quand k augmente, la dilution compense l’augmentation du nombre d’attaquants :

$$\text{Flux total vers } t = k \times \frac{\text{PR}(a_i)}{k} = \text{PR}(a_i) \approx \text{const.}$$

De plus, la masse circule principalement *entre les attaquants*, créant une rétention interne qui profite peu à la cible.

5.3 Anneau : efficacité intermédiaire avec saturation

L’anneau est plus efficace que le complet pour de petits k (il dépasse systématiquement le complet pour $k \leq 5\text{--}10$), mais les deux convergent vers des performances similaires au delà de $k \approx 50$.

Explication. L’anneau force la masse à traverser la cible à chaque tour de cycle, créant un effet d’amplification local pour petit k . Mais quand k augmente, le tour de cycle devient plus long, diluant le “retour” vers la cible à chaque étape intermédiaire. De plus, l’arc supplémentaire ajouté à la cible (vers a_1) augmente son degré sortant d’une unité, réduisant légèrement la fraction de masse qu’elle reçoit de chaque lien entrant. Le gain croît jusqu’à un pic vers $k = 20\text{--}25$ puis décroît.

5.4 Impact du type de cible : effet de levier

Un résultat frappant est que **les cibles faiblement référencées sont relativement plus faciles à booster**. Avec $k = 100$ isolés :

- Cible forte ($PR_0 = 0,00284$) : gain de $8,9\times$;
- Cible médiane ($PR_0 = 0,000646$) : gain de $33,8\times$;
- Cible faible ($PR_0 = 0,000300$) : gain de $71,7\times$.

Cela s'explique par l'**effet de levier** : pour un accroissement absolu fixe $\Delta\pi$, le gain relatif est $\gamma = 1 + \Delta\pi/PR_0$, qui est d'autant plus grand que PR_0 est petit.

6 Comparaison multi-graphes

6.1 Vue d'ensemble

Afin de tester la généralisabilité des résultats, les mêmes attaques ont été appliquées aux trois graphes décrits dans le tableau 1. Les caractéristiques de convergence du PageRank initial diffèrent notablement : `courtois.txt` ($n = 8$) converge en 42 itérations, `Harvard500.mtx` en 47, et `Wikipedia` en seulement 35 itérations malgré sa taille ($n = 1,6$ M) — ce qui s'explique par sa structure fortement connexe.

Remarque 6.1. Sur `Harvard500`, la vérification dense vs. CSR donne $\|\pi_{\text{dense}} - \pi_{\text{CSR}}\|_1 = 6,93 \times 10^{-14}$, confirmant la correction de l'implémentation.

6.2 Comportement sur le graphe jouet `courtois.txt`

Sur ce graphe de 8 nœuds, les scores PR_0 des cibles sont beaucoup plus élevés (de l'ordre de 10^{-1}), rendant l'effet de levier quasi nul. Les gains observés à $k = 100$ sont donc structurellement plus faibles : la cible faible ne dépasse que $\gamma \approx 3,2\times$ avec les isolés, contre $71,7\times$ sur `Harvard500`.

Un phénomène notable apparaît sur ce petit graphe : l'attaque par anneau produit un **gain initial inférieur à 1** pour la cible forte ($\gamma = 0,43$ à $k = 1$), c'est-à-dire qu'elle *dégrade* le score de la cible. Ceci s'explique par le fait que l'arc ajouté de la cible vers a_1 augmente son degré sortant et dilue la masse que la cible reçoit de ses voisins originaux — un effet qui disparaît sur des graphes plus grands où la cible a déjà un degré sortant élevé.

Table 4: Gain relatif γ sur `courtois.txt` ($n = 8$, $k_{\max} = 100$)

Cible	Structure	$k = 1$	$k = 10$	$k = 50$	$k = 100$
Forte	Isolés	1,24×	2,18×	2,83×	2,97×
	Complet	1,24×	1,18×	0,87×	0,26×
	Anneau	0,43×	0,43×	0,15×	0,08×
Médiane	Isolés	1,35×	2,75×	3,71×	3,91×
	Complet	1,35×	1,42×	1,05×	0,32×
	Anneau	0,59×	0,64×	0,23×	0,12×
Faible	Isolés	1,26×	2,31×	3,04×	3,19×
	Complet	1,26×	1,24×	0,91×	0,27×
	Anneau	1,06×	1,04×	0,36×	0,20×

6.3 Comportement sur Wikipedia ($n = 1,6$ M)

Sur le graphe Wikipedia, les expériences ont été limitées à $k_{\max} = 20$ en raison du coût de calcul. Les gains absolus sont nettement plus modestes qu’sur Harvard500, illustrant l’effet de dilution à grande échelle.

Table 5: Gain relatif γ sur Wikipedia ($n = 1,634\,989$, $k_{\max} = 20$)

Cible	Structure	$k = 1$	$k = 5$	$k = 10$	$k = 20$
Forte	Isolés	1,11×	1,56×	2,11×	3,22×
	Complet	1,11×	1,35×	1,47×	1,58×
	Anneau	1,14×	1,43×	1,60×	1,71×
Médiane	Isolés	1,61×	4,04×	7,08×	13,16×
	Complet	1,61×	2,90×	3,59×	4,16×
	Anneau	1,83×	3,47×	4,37×	4,91×
Faible	Isolés	1,85×	5,25×	9,50×	18,00×
	Complet	1,85×	3,66×	4,62×	5,42×
	Anneau	1,95×	4,27×	5,62×	6,46×




Figure 5: Gain relatif sur Wikipedia. Les isolés progressent linéairement ; complet et anneau saturent rapidement. Les gains absolus sont plus faibles qu’sur Harvard500 en raison de la dilution liée à la taille du graphe.

6.4 Comparaison synthétique des trois graphes

La figure 6 compare, pour l’attaque par nœuds isolés (la plus efficace), le gain relatif de la cible faible sur les trois graphes en fonction de k .




Figure 6: Gain relatif de la cible faible sous attaque isolés, sur les trois graphes. La pente est similaire pour Harvard500 et Wikipedia, mais nettement plus faible pour courtois.txt où les scores initiaux sont élevés (effet de levier réduit).

6.5 Analyse des différences entre graphes

Trois phénomènes expliquent les écarts de comportement :

1. Effet de levier et score initial. Le score PR_0 des cibles étant beaucoup plus élevé sur `courtois.txt` (ordre 10^{-1}) que sur Harvard500 (ordre 10^{-4}) ou Wikipedia (ordre 10^{-7}), l’effet de levier $\gamma = 1 + \Delta\pi/PR_0$ est structurellement plus faible. Sur Wikipedia, les cibles faibles ont des scores initiaux quasi nuls, ce qui explique que même un petit k produit un gain relatif impressionnant.

2. Dilution avec la taille du graphe. L’accroissement absolu $\Delta\pi$ apporté par k attaquants dépend de $1/(n+k)$ via le terme de téléportation. Pour $n = 1,6$ M, cette contribution est de l’ordre de 6×10^{-7} par attaquant, contre 2×10^{-3} pour $n = 500$. La pente du gain isolés est donc environ 4000 fois plus faible en valeur absolue sur Wikipedia — mais le faible PR_0 des cibles compense cet effet en termes relatifs.

3. Inversion anneau/complet sur les petits graphes. Sur `courtois.txt`, l’anneau est systématiquement **plus mauvais** que le complet et même que ne rien faire pour la cible forte. L’arc ajouté cible $\rightarrow a_1$ représente une fraction significative du degré sortant total de la cible sur un petit graphe peu dense, ce qui divise la masse qu’elle retient. Sur Harvard500 et Wikipedia, ce même arc est négligeable face au degré sortant déjà élevé de la cible, et l’anneau surpasse bien le complet pour les petits k .

6.6 Tableau de comparaison à $k = 10$

Table 6: Gain relatif γ à $k = 10$ pour les trois graphes et les trois structures

Graphe	Structure	Forte	Médiane	Faible
<code>courtois</code> ($n = 8$)	Isolés	2,18×	2,75×	2,31×
	Complet	1,18×	1,42×	1,24×
	Anneau	0,43×	0,64×	1,04×
Harvard500 ($n = 500$)	Isolés	1,93×	4,86×	9,31×
	Complet	1,38×	2,63×	4,53×
	Anneau	1,54×	3,24×	5,94×
Wikipedia ($n = 1,6$ M)	Isolés	2,11×	7,08×	9,50×
	Complet	1,47×	3,59×	4,62×
	Anneau	1,60×	4,37×	5,62×

On constate que les résultats sur Harvard500 et Wikipedia sont qualitativement cohérents : l’ordre isolés $>$ anneau $>$ complet est respecté pour les cibles médiane et faible sur les deux graphes. `courtois.txt` constitue un cas spécial où la petite taille du graphe inverse le comportement de l’anneau.

7 Règles empiriques et conclusion

7.1 Règles empiriques

À partir de l'ensemble des expériences, on déduit les règles suivantes :

1. **Les nœuds isolés sont l'attaque optimale.** Pour un budget k fixé, des attaquants sans liens mutuels maximisent le flux vers la cible. La croissance est linéaire et ne sature pas.
2. **Le graphe complet est inefficace à grande échelle.** Les liens internes diluent la masse et créent une rétention qui plafonne le gain autour de $1,3\text{--}5,5\times$ selon la cible.
3. **L'anneau est intéressant pour de petits k , sur des graphes de taille moyenne ou grande.** Pour $k \leq 10$, il surpasse le graphe complet grâce à la boucle de renforcement. Au-delà de $k = 30$, son avantage disparaît. Sur les très petits graphes, l'anneau peut même dégrader le score cible.
4. **Cibler les pages faibles maximise l'impact relatif.** L'effet de levier rend le Google Bombing d'autant plus visible que la page cible est peu connue initialement. Ce phénomène est robuste sur les trois graphes testés.
5. **Les résultats sont qualitativement stables entre Harvard500 et Wikipedia.** Malgré un facteur d'échelle de $\times 3000$ sur n , l'ordre des structures et l'effet de levier sont conservés. `courtois.txt` est trop petit pour exhiber les comportements typiques.

7.2 Conclusion

Cette étude montre que le Google Bombing est une attaque effective et quantifiable sur le mécanisme PageRank. Les principaux enseignements sont :

- La structure d'attaque optimale est l'**étoile entrante pure** (nœuds isolés), dont le gain croît linéairement sans saturation, pouvant atteindre un facteur $\times 72$ avec 100 attaquants sur Harvard500 et $\times 18$ dès $k = 20$ sur Wikipedia.
- Les liens intra-attaquants (complet, anneau) *nuisent* à l'efficacité de l'attaque à grande échelle en créant une rétention de masse interne. Sur les petits graphes, l'anneau peut même être contre-productif.
- L'effet est d'autant plus spectaculaire que la cible est peu référencée initialement — ce qui correspond exactement au cas d'usage réel du Google Bombing — et ce résultat est robuste à l'échelle.

Ces résultats justifient les contre-mesures adoptées par les moteurs de recherche modernes : détection de fermes de liens, prise en compte de la qualité des liens entrants, et diversification des signaux de pertinence au-delà de la seule topologie du graphe.

References

- [1] S. Brin, L. Page, *The Anatomy of a Large-Scale Hypertextual Web Search Engine*, Computer Networks and ISDN Systems, 30(1–7):107–117, 1998.
- [2] A. N. Langville, C. D. Meyer, *Google’s PageRank and Beyond: The Science of Search Engine Rankings*, Princeton University Press, 2006.
- [3] M. Bianchini, M. Gori, F. Scarselli, *Inside PageRank*, ACM Transactions on Internet Technology, 5(1):92–128, 2005.
- [4] T. A. Davis, Y. Hu, *The University of Florida Sparse Matrix Collection*, ACM Transactions on Mathematical Software, 38(1):1–25, 2011.